Aprendizagem Ativa Sensível à Equidade na Previsão de Respostas a Candidaturas: Supervisão Humana, Erro por Grupo e Compromissos na Aquisição

Pedro Pais Dinis Pedro Miguel Gonçalves Dias
Inteligência Artificial Fiável e Responsável - Trabalho Prático 1
Mestrado em Inteligência Artificial - Universidade de Coimbra

Resumo

Os modelos treinados com decisões históricas de recrutamento podem reproduzir desigualdades presentes nesses dados. Neste trabalho estudamos se a aprendizagem ativa, combinada com informação sobre os erros de diferentes grupos e intervenção humana, altera o desempenho de um classificador que prevê respostas a candidaturas. Utilizámos 4 870 registos do conjunto *Resume*, implementámos estratégias convencionais de seleção e uma abordagem própria que considera a incerteza do modelo e o erro de validação por grupo racial. Desenvolvemos também uma interface *Human-in-the-Loop* (HITL), na qual uma pessoa decide a política de aquisição de cada lote. Com 400 exemplos rotulados, a seleção ponderada por densidade atingiu os melhores valores observados de *balanced accuracy* (0,5664) e F1 (0,1926); a estratégia proposta obteve 0,5309 e 0,1224. Num ensaio de dez rondas, o supervisor alterou sete lotes. Numa comparação adicional com cinco sementes e 230 rótulos, a versão por regras inspirada na supervisão reduziu a diferença média de *equalized odds* de 0,0670 para 0,0389, com ligeira redução do desempenho preditivo. Os resultados revelam compromissos entre precisão, equidade e controlo humano, sem demonstrarem uma melhoria universal. **Palavras-chave:** aprendizagem ativa; equidade; recrutamento; supervisão humana; HITL; *equalized odds*.

1 Introdução

O recrutamento é um contexto importante para estudar inteligência artificial responsável. Quando um sistema aprende a partir de respostas históricas de empregadores, pode reproduzir diferenças que já existiam nos processos de seleção. Por isso, prever se uma candidatura recebeu uma resposta não é o mesmo que avaliar o mérito da pessoa candidata. O resultado registado no conjunto de dados não deve ser interpretado como uma decisão justa por definição.

A aprendizagem ativa procura reduzir a quantidade de exemplos que precisam de ser rotulados. Em vez de utilizar todos os registos de imediato, o sistema escolhe sucessivamente os que considera mais úteis, obtém os respetivos rótulos e volta a treinar. Contudo, selecionar apenas os exemplos sobre os quais o modelo tem mais dúvidas não garante que os erros sejam semelhantes entre grupos demográficos.

A nossa pergunta de investigação foi: *de que forma uma estratégia de aprendizagem ativa que considera o erro por grupo e permite intervenção humana afeta o desempenho preditivo e as diferenças de erro entre grupos?* Para a responder, construímos um processo com pré-processamento, comparação de estratégias, aquisição sensível à equidade e supervisão humana. O supervisor não decide contratar ninguém: pode escolher quais os exemplos históricos que serão adicionados ao treino. A contribuição principal está nessa ligação entre estratégia de aquisição, auditoria do erro e controlo da seleção por uma pessoa.

2 Enquadramento Conceptual

2.1 Aprendizagem ativa e estratégias de seleção

Na aprendizagem ativa baseada numa *pool*, o modelo começa com um pequeno conjunto rotulado e tem à disposição muitos exemplos ainda não utilizados no treino. A cada ronda, seleciona um lote, recebe os rótulos correspondentes e atualiza o classificador. No nosso caso, os rótulos são respostas históricas já existentes no dataset, temporariamente ocultadas ao modelo. Assim, a aquisição é simulada de forma reprodutível.

O estudo começou com quatro estratégias: amostragem aleatória, menor confiança, entropia e margem. A menor confiança privilegia os exemplos para os quais o modelo atribui probabilidades semelhantes às duas classes; a entropia e a margem são outras formas de medir a incerteza. Na primeira experiência, estas três variantes tiveram curvas praticamente sobrepostas. Para diversificar a avaliação, passámos a utilizar *query-by-committee* (QBC), que mede desacordo entre previsões, e ponderação por densidade, que combina incerteza e concentração dos exemplos na *pool*. A comparação alargada incorporou depois a estratégia sensível ao erro por grupo.

2.2 Equidade e papel do supervisor

Uma avaliação responsável não deve olhar apenas para a precisão média: deve também observar se o modelo comete erros diferentes em grupos distintos. Centrámos a análise de equidade na raça, usando os grupos *Black* e *White* definidos nos dados. O género e as combinações de raça e género foram igualmente considerados na

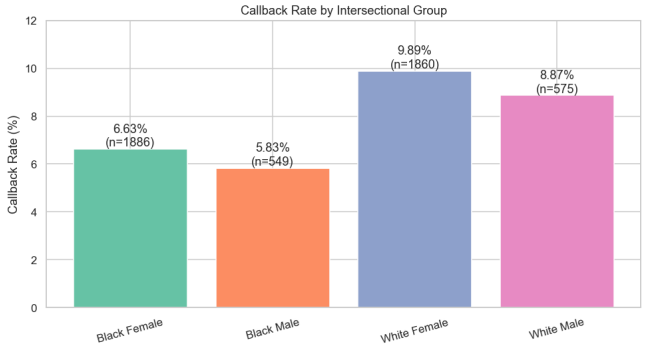


Figura 1: Taxa de resposta histórica por combinação de raça e género. Trata-se de uma característica dos dados, não de um erro do modelo.



Figura 2: Percentagens de valores em falta encontradas durante a exploração dos dados.

exploração inicial.

Utilizámos a diferença de *equalized odds* (EOD) para resumir a maior diferença entre as taxas de verdadeiros positivos ou falsos positivos dos dois grupos. A sua definição pode ser resumida numa única expressão simples:

$$\mathrm{EOD} = \max(\Delta\mathrm{TPR},\ \Delta\mathrm{FPR}),$$

em que os dois termos representam as diferenças absolutas entre grupos nas taxas de verdadeiros e falsos positivos. Quanto menor for a EOD, mais próximas estão essas taxas; no entanto, um modelo que quase nunca prevê uma resposta positiva pode ter EOD baixa e, ao mesmo tempo, pouca utilidade. Também é importante distinguir representatividade dos exemplos adquiridos e equidade dos erros: uma não garante a outra.

No nosso sistema HITL, a pessoa intervém sobre a política de seleção dos lotes, enquanto os rótulos continuam a ser obtidos dos dados históricos. Esta escolha permite testar supervisão da aquisição sem pedir ao participante que adivinhe qual teria sido a resposta do empregador a um currículo.

3 Materiais e Métodos

3.1 Dataset e exploração inicial

Utilizámos o conjunto *Resume*, com 4 870 candidaturas e 30 colunas originais. A variável `received_callback` indica se existiu uma resposta do empregador. Das observações, 2 435 pertencem a cada grupo racial; 3 746 estão classificadas como femininas e 1 124 como masculinas. Apenas 392 candidaturas (8,05%) receberam resposta positiva, tornando o problema bastante desequilibrado. A taxa de resposta histórica foi de 6,45% no grupo *Black* e 9,65% no grupo *White*.

A exploração incluiu o equilíbrio das classes, respostas por raça e género, grupos interseccionais, valores em falta e distribuição de variáveis quantitativas. A Figura 1 mostra diferenças entre os quatro grupos interseccionais. A Figura 2 resume duas variáveis com mais valores em falta. Estas diferenças descritivas justificam a análise dos erros do modelo, mas não demonstram, por si só, discriminação individual.

3.2 Preparação dos dados

Convertemos os campos numéricos e binários, aplicámos codificação *one-hot* às variáveis categóricas e tratámos os valores em falta. Para as variáveis numéricas foi usada a mediana; nas categóricas, uma categoria própria para valores ausentes. O valor textual `some` nos requisitos mínimos de experiência foi representado por 0,5, uma opção prática de conversão. No final, obtivemos 43 características para o classificador.

Retirámos dos preditores a resposta a prever, o primeiro nome, o identificador do anúncio, a raça e o género. Os atributos sensíveis foram guardados à parte para analisar os resultados e orientar a estratégia proposta. Esta exclusão evita a utilização direta desses campos pelo classificador, mas não impede que existam variáveis correlacionadas com eles.

As candidaturas foram separadas em desenvolvimento e teste por identificador de anúncio, para evitar anúncios repetidos nos dois conjuntos: 3 904 registos ficaram no desenvolvimento e 966 no teste. Destes, escolhemos 200 exemplos inicialmente rotulados, deixando 3 704 na *pool*. Na experiência sensível à equidade, separámos ainda 500 exemplos para validação, permanecendo 3 204 candidatos. O pré-processamento foi ajustado apenas nos 200 exemplos iniciais e aplicado aos restantes conjuntos sem novo ajuste.

3.3 Modelo, aquisição e avaliação

Nas comparações principais, utilizámos uma *Random Forest* com 200 árvores, profundidade máxima de seis níveis, pelo menos cinco exemplos por folha e ponderação equilibrada das classes. Esta configuração substituiu uma versão preliminar menos restringida, que produzia poucas previsões positivas. A alteração foi motivada pelo diagnóstico exploratório e não resultou de uma otimização sistemática de hiperparâmetros. Em cada ronda, a estratégia escolhe exemplos ainda não rotulados, os respetivos callbacks históricos são revelados apenas nessa etapa e o modelo volta a ser treinado.

Propusemos também uma seleção sensível ao erro por grupo. Primeiro, avaliamos numa amostra de validação o erro do modelo para exemplos positivos e negativos de cada grupo racial, dando a mesma importância às duas classes. Depois, combinamos esse indicador com a incerteza individual de cada exemplo da *pool*, com pesos iguais. Assim, um exemplo pode ter prioridade por ser incerto, por pertencer a um grupo em que o modelo

tem mais dificuldades ou por ambos os motivos. Esta prioridade não corresponde diretamente à EOD, pelo que não existe garantia de que melhore essa métrica.

O desempenho foi avaliado com *balanced accuracy* (média da capacidade de identificar respostas e não respostas), F1 (equilíbrio entre precisão e recuperação dos callbacks), *average precision* (AP, sensível ao desempenho na classe positiva) e EOD. Também observámos as previsões positivas e a composição racial dos lotes selecionados. As métricas foram calculadas com o limiar de classificação de 0,5. O teste foi utilizado para apresentar os resultados do estudo, não como sinal direto da estratégia de aquisição.

3.4 Interface Human-in-the-Loop

A primeira interface permitia aprovar individualmente os exemplos, mas essa escolha não alterava a seleção quando todos eram aceites. Por isso, passámos a permitir que o supervisor escolhesse a política de aquisição por lote. A interface final mostra as prioridades dos grupos, a composição racial proposta e as aquisições anteriores. O supervisor pode escolher manter a seleção sensível à equidade (A), privilegiar a presença dos dois grupos no lote (B) ou selecionar apenas por incerteza (C), indicando uma justificação. A opção B escolhe um exemplo *Black* e dois *White* num lote de três, quando disponíveis; não corresponde a paridade exata entre os grupos.

O sistema regista a política, os identificadores adquiridos, a composição racial e se a seleção foi alterada face à proposta automática. Os rótulos históricos continuam a ser revelados por um *oracle* simulado, e não pelo supervisor. O notebook inclui, além da sessão interativa, uma regra automática inspirada nessas decisões para permitir repetições com sementes diferentes; esta regra não substitui cinco participações humanas independentes.

4 Desenho Experimental

4.1 Fases e decisões metodológicas

As experiências foram organizadas em três fases, com objetivos distintos. Na **Fase I**, começámos por comparar amostragem aleatória, menor confiança, entropia e margem, em 20 lotes de dez exemplos, dos 200 aos 400 rótulos. A Figura 3 documenta os resultados desta primeira tentativa. As três estratégias de incerteza apresentaram curvas quase idênticas e o F1 manteve-se próximo de zero durante a maior parte das rondas. Estes resultados levaram-nos a rever a configuração do classificador e a procurar baselines que selecionassem exemplos por critérios diferentes.

Ainda como desenvolvimento dos baselines, substituímos entropia e margem por QBC e ponderação por densidade. A Figura 4 apresenta as curvas desta comparação já diversificada, antes de introduzir o método sensível à equidade. Os valores desta experiência e os do diagnóstico inicial não devem ser tratados como repetições diretamente comparáveis, pois refletem opções de modelação diferentes.

Na **Fase II**, mantivemos as quatro estratégias diversificadas e acrescentámos a aquisição sensível ao erro por grupo (Figura 5). Foram reservados 500 exemplos de validação para determinar as prioridades raciais, mantendo 200 novas aquisições por estratégia e um total final de 400 exemplos rotulados.

Tabela 1: Resultados finais com 400 exemplos rotulados na comparação de cinco estratégias (Fase II).

Estratégia	BalAcc	F1	AP	EOD
Aleatória	.5060	.0471	.1058	.0046
Menor confiança	.5281	.1165	.1306	.1335
QBC	.5154	.0825	.1130	.0690
Pond. densidade	.5664	.1926	.1252	.0282
Erro por grupo	.5309	.1224	.1232	.0735

Na **Fase III**, realizámos dez rondas HITL, com três exemplos por lote, entre 200 e 230 rótulos. A sessão humana foi comparada com um processo inteiramente automático com o mesmo orçamento. Uma experiência complementar repetiu uma regra inspirada no protocolo humano com cinco sementes (10, 21, 42, 73 e 99), sem alterar a divisão dos dados. A regra escolhe a política B se o lote automático contiver apenas um grupo e se a diferença entre as respetivas prioridades for inferior a 0,10; nos outros casos, conserva a política A. O limiar de 0,10 é heurístico, não estatisticamente otimizado.

5 Resultados

5.1 Diagnóstico inicial e comparação das estratégias

Na primeira experiência, a *balanced accuracy* permaneceu aproximadamente entre 0,506 e 0,514 e o F1 entre 0,03 e 0,06. Ao atingir 400 rótulos, a seleção aleatória apresentou *balanced accuracy* de 0,5064 e F1 de 0,0286; menor confiança, entropia e margem terminaram com 0,5138 e 0,0563. A coincidência destas três curvas não significava que os métodos tivessem produzido melhorias independentes. Pelo contrário, tornou visível a dificuldade em identificar a classe positiva num problema em que só 8,05% dos registos apresentam callback. Foi este diagnóstico que sustentou a revisão da *Random Forest* e a escolha de critérios de aquisição mais diversificados.

Na comparação seguinte, já com QBC e ponderação por densidade, o desempenho foi menos uniforme (Figura 4). Com 400 rótulos, o QBC apresentou a maior *balanced accuracy* (0,5231) e F1 (0,1071) deste conjunto de quatro baselines, enquanto a menor confiança atingiu AP de 0,1245. A diferença em relação ao ensaio exploratório reforçou a necessidade de analisar as curvas completas e não apenas uma medição final.

Na comparação de cinco estratégias, a ponderação por densidade alcançou a maior *balanced accuracy* (0,5664) e F1 (0,1926), enquanto a menor confiança obteve a maior AP (0,1306). A aquisição sensível ao erro por grupo registou 0,5309, 0,1224, 0,1232 e 0,0735 para *balanced accuracy*, F1, AP e EOD, respetivamente (Tabela 1; Figura 5). A amostragem aleatória terminou com EOD de 0,0046, mas desempenho preditivo reduzido; uma disparidade pequena não torna automaticamente o classificador preferível.

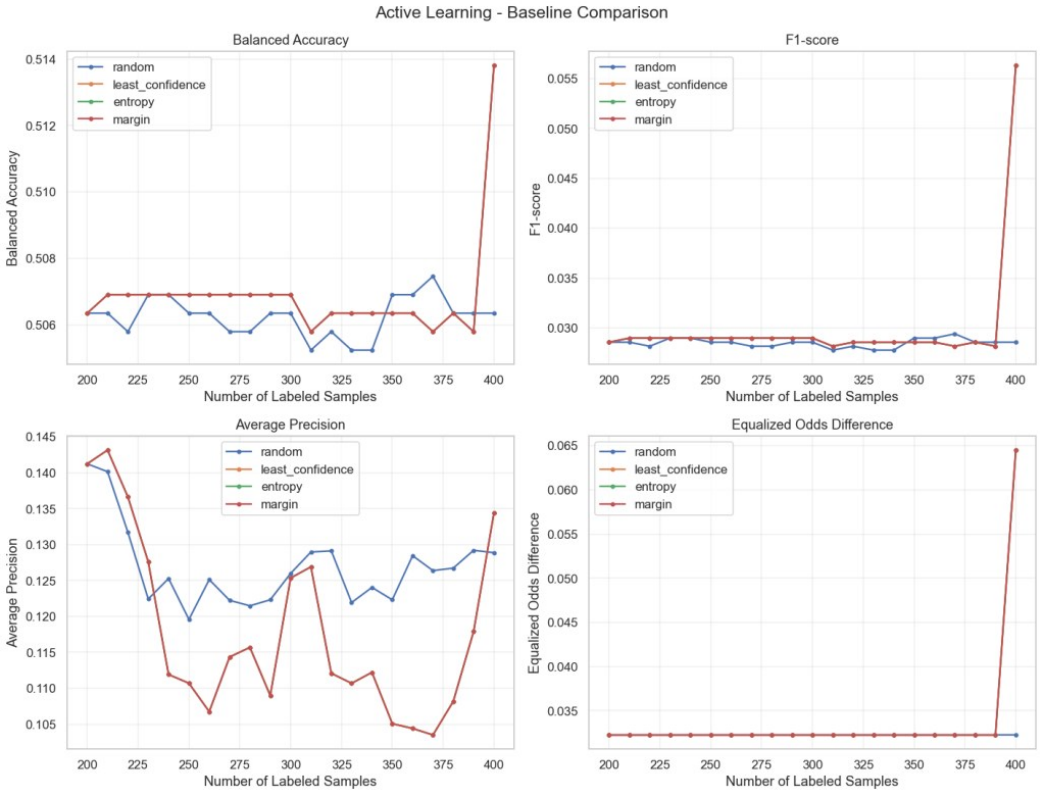


Figura 3: Diagnóstico exploratório: amostragem aleatória, menor confiança, entropia e margem. A sobreposição das estratégias de incerteza e o baixo F1 motivaram a revisão do classificador e a diversificação das políticas de aquisição.

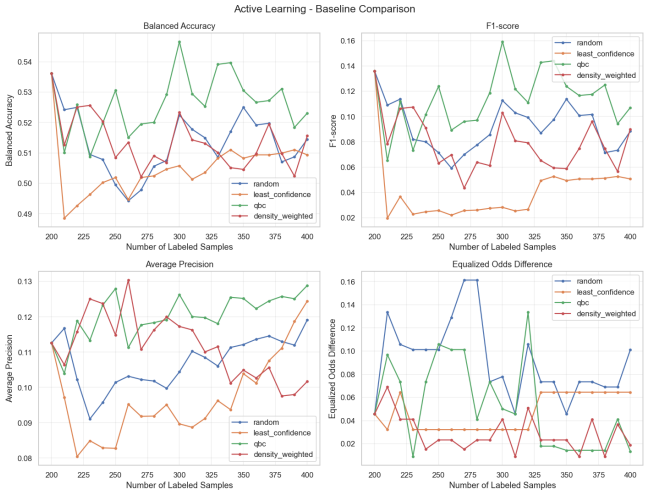


Figura 4: Comparação dos baselines diversificados: amostragem aleatória, menor confiança, QBC e ponderação por densidade, antes da introdução do critério de erro por grupo.

5.2 Supervisão humana em dez rondas

O supervisor escolheu a política B em sete lotes e conservou a política A em três; a alternativa C não foi utilizada nessa sessão. A comparação de identificadores confirma que sete de dez lotes foram alterados (70%). No total, foram adquiridos 16 exemplos *Black* e 14 *White*. As políticas adotadas e a composição das aquisições estão ilustradas na Figura 6.

A execução automática terminou com *balanced accuracy* de 0,5236 e EOD de 0,0735, enquanto a sessão HITL terminou com 0,4852 e 0,0323, respetivamente (Tabela 2; Figura 7). O supervisor conseguiu mudar os exemplos utilizados no treino e a disparidade medida diminuiu, mas houve uma perda importante de capacidade preditiva. O valor de *balanced accuracy* inferior a 0,5 nesta sessão torna essa ressalva especialmente importante.

Tabela 2: Resultados da sessão interativa com dez lotes.

Indicador	Automático	HITL
Exemplos rotulados	230	230
Balanced accuracy	.5236	.4852
EOD	.0735	.0323
Lotes alterados	–	7/10
Aquisições Black / White	–	16 / 14

5.3 Estudo com cinco sementes (seeds)

A experiência complementar repetiu uma regra inspirada no protocolo HITL, mas sem solicitar novas escolhas humanas. Em média, a EOD passou de 0,0670 para 0,0389, enquanto a *balanced accuracy* passou de 0,5277 para 0,5234 e o F1 de 0,1122 para 0,1010. A AP mudou pouco (0,1244 no modo automático e 0,1255 no modo supervisionado). A Tabela 3 apresenta a variação entre sementes e a Figura 8 mostra as curvas correspondentes. As áreas sombreadas representam um desvio-padrão, não intervalos de confiança.

A diferença nas aquisições ajuda a compreender os resultados: o modo automático escolheu em média 29 exemplos *Black* e um *White*; a regra supervisionada escolheu 10,2 *Black* e 19,8 *White*, alterando em média 9,8 lotes. Isto confirma uma mudança expressiva na seleção, mas não prova que a política seja superior em todos os contextos.

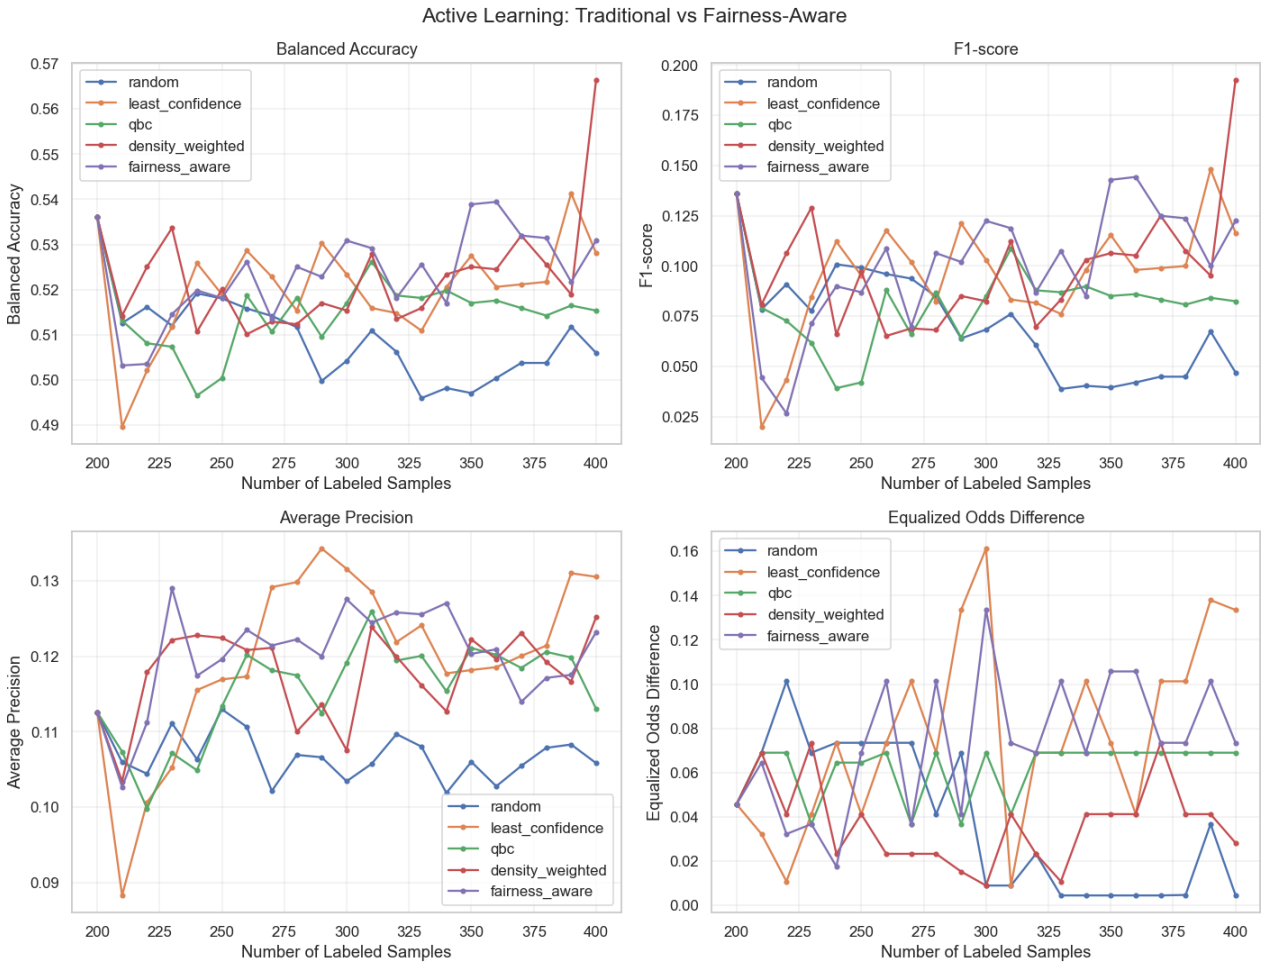


Figura 5: Comparação final das cinco estratégias com o mesmo orçamento: *balanced accuracy*, F1, AP e diferença de *equalized odds*.

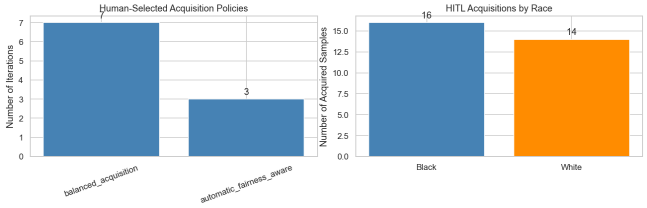


Figura 6: Políticas escolhidas pelo supervisor e composição dos 30 exemplos adquiridos na sessão HITL.

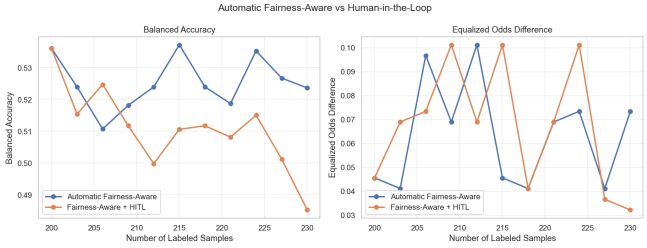


Figura 7: Evolução da *balanced accuracy* e da EOD nas dez rondas com seleção automática e com decisões humanas registadas.

Tabela 3: Média e desvio-padrão das métricas finais em cinco sementes, aos 230 rótulos.

Indicador	Automático	Por regras
Bal. accuracy	$.5277 \pm .0102$	$.5234 \pm .0101$
F1	$.1122 \pm .0277$	$.1010 \pm .0315$
AP	$.1244 \pm .0064$	$.1255 \pm .0132$
EOD	$.0670 \pm .0248$	$.0389 \pm .0235$
Prev. positivas	33.8 ± 16.2	30.0 ± 11.9

6 Discussão

6.1 O que as experiências mostram

A fase exploratória foi importante para orientar o projeto. Quando menor confiança, entropia e margem produziram praticamente as mesmas curvas e poucas respostas positivas, percebemos que não bastava repetir variantes muito próximas de seleção por incerteza. A revisão da configuração do classificador e a inclusão de QBC e densidade deram origem a uma comparação mais informativa. Esta sequência deve ser interpretada como desenvolvimento experimental, e não como evidência de que os resultados iniciais e finais são estimativas independentes.

Os resultados finais confirmam que a escolha da política depende da métrica valorizada. A ponderação por densidade teve o melhor F1 e a melhor *balanced accuracy* observados na comparação de cinco estratégias; a aquisição sensível ao erro por grupo não foi superior em todas as medidas. O indicador de erro por grupo introduz uma prioridade explícita para dificuldades detetadas na validação, mas não otimiza diretamente a EOD. A evolução das métricas é irregular, pelo que uma única execução não demonstra superioridade estatística.

A intervenção humana alterou realmente os exemplos incorporados no treino. O supervisor analisou a composição dos lotes propostos, optou por conservar ou substituir a política e registou as razões. A composição das aquisições mudou, bem como as curvas de desempenho. Porém, na sessão interativa a EOD menor coincidiu com *balanced*

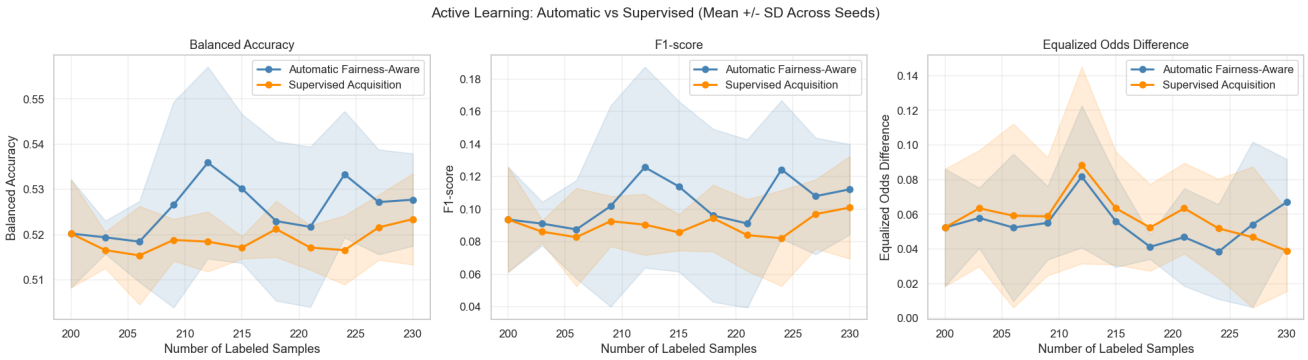


Figura 8: Médias e desvios-padrão de cinco sementes para seleção automática e aquisição por regras inspiradas na supervisão humana. As divisões dos dados são as mesmas.

accuracy inferior a 0,5; no estudo por regras observou-se uma redução média de EOD, acompanhada por ligeiras perdas de *balanced accuracy* e F1. A representatividade dos lotes não equivale, por si só, a igualdade de erros.

6.2 Limitações e supervisão responsável

Os rótulos representam decisões históricas dos empregadores e não avaliações independentes do mérito dos candidatos. O protótipo prevê essas respostas históricas, sem decidir contratações. Além disso, as classes são muito desequilibradas: alterações de poucas previsões positivas podem provocar variações relevantes na EOD. Um modelo que quase sempre prevê ausência de resposta pode até apresentar disparidade reduzida sem ser preditivamente útil.

O humano controla a política de aquisição, mas não atribui os rótulos: estes são revelados por um *oracle* simulado. A experiência com cinco sementes reproduz uma regra definida a partir do protocolo, não cinco sessões com pessoas distintas. As sementes alteram a aleatoriedade do classificador, mantendo a mesma divisão de desenvolvimento e teste. As sucessivas avaliações na fase de desenvolvimento também aconselham prudência ao interpretar o teste como inteiramente independente das opções metodológicas. Finalmente, a auditoria concentrou-se na raça; as interseções com género foram exploradas descritivamente, mas não orientaram a aquisição.

Excluir raça e género dos preditores não impede que existam características correlacionadas. Da mesma forma, a política B garante presença dos dois grupos em lotes de três (um exemplo *Black*, dois *White*, quando disponíveis), mas não paridade exata nem igualdade de taxas de erro. A não utilização da política C na sessão interativa limita a comparação a decisões efetivamente observadas. A aplicação real exigiria salvaguardas de privacidade, mecanismos de responsabilização, novos rótulos e avaliação com vários supervisores.

7 Conclusões e Trabalho Futuro

Implementámos um protótipo de aprendizagem ativa para prever respostas históricas a candidaturas e avaliámos uma forma de incluir supervisão humana na escolha dos exemplos a adquirir. Os resultados indicam que reduzir a disparidade entre grupos não significa necessariamente aumentar a utilidade preditiva. A seleção por erro de grupo e a intervenção humana podem mudar o processo de aquisição, mas devem ser acompanhadas por uma análise conjunta do desempenho, das diferenças de erro e do contexto social dos dados.

Como trabalho futuro, propomos repetir o estudo com novas divisões dos dados e mais sementes, comparar taxas de verdadeiros e falsos positivos separadamente para cada grupo, analisar calibração e limiares de decisão, estudar subgrupos interseccionais e envolver vários supervisores. O protótipo é uma experiência académica de supervisão da aprendizagem, não uma ferramenta de contratação.

Em relação aos objetivos da unidade curricular, o trabalho permitiu explorar duas dimensões complementares da IA fiável e responsável. A primeira é a equidade: verificámos que não basta medir a precisão geral e que é necessário compreender como os erros se distribuem pelos grupos. A segunda é a supervisão humana: criámos uma oportunidade concreta para uma pessoa analisar o estado do processo, escolher uma alternativa e deixar um registo da decisão. A intervenção foi real no sentido de alterar os dados que entraram no treino, embora a atribuição dos rótulos tenha permanecido simulada.

Uma dificuldade central foi conciliar objetivos que nem sempre evoluíram na mesma direção. Em algumas rondas, os resultados pareceram favorecer a redução da disparidade; noutras, as métricas preditivas pioraram. O protótipo permite observar e discutir esses efeitos, em vez de pressupor uma solução automática para o problema da equidade. O sistema pode servir de ponto de partida para experiências futuras com mais participantes e com regras de intervenção avaliadas de forma independente.

Disclaimer de uso de AI: A revisão e organização do texto tiveram apoio do modelo ChatGPT. No entanto, a responsabilidade pelo conteúdo, os resultados e conclusões obtidos, são da autoria e da responsabilidade dos autores.